

Sentimento como Relevância: Recomendação de Produtos em E-commerce Brasileiro

Cilene Renata Real¹, Jayme Sakae dos Reis Furuyama¹, Wesley Nogueira Galvão³, ¹Programa de Pós-Graduação em Ciência da Computação (PPGCC), Universidade Federal de São Carlos (UFSCar), São Carlos, SP, Brasil

{real.cilene, jaymefuruyama}@gmail.com
wesleygalvao@estudante.ufscar.br

Resumo—A análise de sentimentos em avaliações de produtos é uma das tarefas mais estudadas em Processamento de Linguagem Natural (PLN), com forte aplicabilidade em plataformas de e-commerce. Este trabalho propõe um sistema integrado de duas etapas: (i) um classificador de polaridade de sentimento (positivo/negativo) a ser treinado sobre avaliações em português brasileiro do corpus B2W-Reviews01, comparando representações baseadas em TF-IDF e *embeddings* contextuais do BERTimbau; e (ii) um motor de recomendação de produtos que recuperará itens semanticamente similares pelo título, re-ranqueando os resultados por um *score* de positividade derivado do modelo com melhor desempenho. Os classificadores serão avaliados com precisão, revocação, F1-macro e AUC-ROC, e o módulo de recomendação com NDCG@k e Precision@k, complementados por avaliação qualitativa conduzida pelos integrantes do grupo. Espera-se que a combinação de representações densas com análise de sentimento agregue valor significativo à qualidade das recomendações em domínios ruidosos de texto gerado por usuário.

I. INTRODUÇÃO

Plataformas de comércio eletrônico acumulam diariamente volumes massivos de avaliações escritas por consumidores. Essas avaliações constituem uma fonte rica de opinião sobre produtos, entrega e experiência de compra, porém permanecem majoritariamente subutilizadas nos sistemas de recomendação tradicionais, que tendem a depender exclusivamente de dados de interação (cliques, compras e notas numéricas) (1).

Análise de sentimentos (AS) é a tarefa de PLN que visa inferir automaticamente a polaridade afetiva de um texto partir de seu conteúdo (2). O seu objetivo é estudar e extrair opiniões, avaliações, atitudes, apreciações e emoções direcionadas a entidades como produtos, serviços, indivíduos, tópicos ou eventos (3). A análise pode ser conduzida em três níveis de granularidade: no nível do documento (avaliando a polaridade geral do texto), no nível da sentença, ou no nível do aspecto

Quando aplicada a avaliações de produtos, ela permite mapear opiniões para um sinal de qualidade que complementa a nota numérica fornecida pelo consumidor. O corpus B2W-Reviews01 (4), formado por mais de 130 mil avaliações da Americanas.com em português brasileiro, é um recurso público representativo desse domínio, com anotações de nota (1–5 estrelas), recomendação binária e metadados demográficos dos avaliadores.

Dois desafios fundamentais motivam este projeto. O primeiro é a representação adequada do texto em português para

tarefas de classificação: abordagens baseadas em vetorização esparsa oferecem uma linha de base eficiente e interpretável (3), enquanto modelos de vetorização densa capturam dependências semânticas e contextuais que as superam em diversas tarefas (5). O segundo desafio é a integração do sinal de sentimento em um motor de recomendação: recuperar produtos similares pelo título por meio de busca vetorial e re-ranquear os resultados pelo índice de positividade das avaliações classifica melhor os itens que os consumidores efetivamente recomendam.

Desta forma, o presente projeto propõe um *pipeline* completo que: (a) realiza análise exploratória e pré-processamento do corpus B2W-Reviews01; (b) compara dois paradigmas de representação textual para classificação de sentimento binária; (c) constrói um banco vetorial dos títulos de produtos; e (d) entrega recomendações re-ranqueadas pelo sentimento. O sistema final é avaliado tanto quantitativamente quanto por análise qualitativa conduzida pelos integrantes do grupo.

O restante do relatório está organizado da seguinte forma: a Seção II apresenta os trabalhos relacionados; a Seção III descreve a metodologia detalhada; e a Seção IV traz as considerações finais e os próximos passos.

II. TRABALHOS RELACIONADOS

A. Análise de Sentimentos em Avaliações de E-commerce

A análise de sentimentos em avaliações de produtos é uma área amplamente estudada. Alzahrani *et al.* (2) propuseram um sistema baseado em aprendizado profundo combinando CNN, LSTM e BERT para classificar avaliações de e-commerce em múltiplas polaridades, obtendo acurácia superior a 94% em conjuntos de dados em inglês. Os autores destacam que avaliações são ruidosas, com erros tipográficos, gírias e linguagem informal, e que o pré-processamento adequado é fundamental para o desempenho dos modelos.

Para o português brasileiro, a situação é mais desafiadora pela escassez de recursos anotados. Sousa e Filho(6) realizaram um estudo comparativo sistemático entre TF-IDF com Regressão Logística (linha de base), *embeddings* do BERTimbau (pré-treinado sem ajuste fino) e BERTimbau com *fine-tuning* em datasets de sentimento em português. Os autores demonstraram que o BERTimbau com *fine-tuning* supera consistentemente a linha de base TF-IDF, atingindo AUC-ROC superior a 0.95 em múltiplos benchmarks, e que a

versão *large* do modelo apresenta ganhos marginais em relação à versão *base*.

B. Modelos de Linguagem Pré-treinados: BERT e BERTimbau

O BERT (*Bidirectional Encoder Representations from Transformers*) (7) revolucionou o PLN ao propor o pré-treinamento bidirecional profundo sobre grandes corpora, seguido de *fine-tuning* supervisionado para tarefas específicas. Diferente de modelos anteriores, o BERT condiciona simultaneamente os contextos esquerdo e direito em todas as suas camadas de atenção, produzindo representações contextuais ricas.

O BERTimbau (8) é a adaptação do BERT para o português brasileiro, pré-treinado no corpus BrWaC (*Brazilian Web as Corpus*) com aproximadamente 2,7 bilhões de palavras. O modelo está disponível nas versões *base* (110M parâmetros) e *large* (335M parâmetros) e estabeleceu novos estados da arte em reconhecimento de entidades nomeadas, similaridade textual e implicação textual em português.

C. TF-IDF como Representação para Classificação de Texto

A ponderação TF-IDF (*Term Frequency–Inverse Document Frequency*) (9) é uma das representações esparsas mais utilizadas em tarefas de classificação de texto. Combinada com classificadores lineares como a Regressão Logística, essa abordagem serve como linha de base interpretável e de baixo custo computacional. Por não capturar dependências contextuais, o TF-IDF com Regressão Logística pode, em certos cenários, apresentar desempenho competitivo frente a modelos mais complexos, especialmente em domínios com vocabulário especializado e textos curtos (6).

D. Recomendação de Produtos Orientada por Sentimento

A integração de análise de sentimentos em sistemas de recomendação tem crescido significativamente. Vaishnavi e Kalpana (10) propuseram um sistema que combina e classifica o sentimento das avaliações com XGBoost e CatBoost e usa a saída para construir matrizes de similaridade item-item baseadas em similaridade de cosseno, reportando melhorias no RMSE frente a sistemas baseados apenas em notas numéricas.

Uma revisão abrangente recente (1) categoriza os sistemas de recomendação orientados por sentimento em quatro grandes abordagens: (i) classificadores de aprendizado profundo que combinam embeddings de sentimento com interações usuário-item; (ii) métodos baseados em Transformers para extração de features; (iii) redes neurais em grafos que propagam sinais de sentimento; e (iv) recomendadores conversacionais que se adaptam em tempo real ao *feedback* do usuário. O trabalho de Darraz *et al.* (11) demonstrou que incorporar sentimento via BERT em filtragem colaborativa reduz o RMSE para 1,2478 em benchmarks do Yelp, reforçando a relevância da abordagem proposta neste projeto.

III. METODOLOGIA

A. Base de Dados

O projeto utiliza o corpus B2W-Reviews01 (4), um conjunto de dados aberto de avaliações de produtos coletadas da

plataforma Americanas.com entre janeiro e maio de 2018.¹ A Tabela I resume as principais características do corpus.

Tabela I
CARACTERÍSTICAS DO CORPUS B2W-REVIEWS01

Característica	Valor
Total de avaliações	132.373
Avaliadores únicos	112.993
Produtos únicos	48.001
Total de tokens	3.160.781
Tokens únicos	148.541
Mediana de tokens/avaliação	16
Período de coleta	Jan–Mai 2018
Idioma	Português Brasileiro
Produtos com nota negativa (1 e 2)	27,02%
Produtos com nota positiva (4 e 5)	60,66%
Produtos com nota neutra (3)	12,33%

Cada instância contém: data de submissão, identificador do avaliador, identificador e nome do produto, marca, categorias de primeiro e segundo nível, nota geral (1–5), recomendação binária a um amigo (Sim/Não), título da avaliação, texto completo da avaliação, ano de nascimento, gênero e estado do avaliador.

1) *Mapeamento de Polaridade*: Trabalhos anteriores sobre o corpus B2W-Reviews01 adotam o mapeamento de notas para polaridade binária descartando avaliações com nota 3 por serem consideradas ambíguas (4). Seguindo essa convenção, este trabalho adota o seguinte mapeamento:

- **Positivo**: notas 4 e 5 estrelas.
- **Negativo**: notas 1 e 2 estrelas.
- **Descartado**: notas 3 estrelas.

2) *Análise Exploratória de Dados*: A etapa de análise exploratória abrange: (i) distribuição de classes pelo mapeamento de polaridade; (ii) distribuição das notas de 1 a 5 estrelas; (iii) análise de dados faltantes nos campos de texto (*review_text*, *review_title*); (iv) frequência de avaliações por categoria de produto (*site_category_lvl1*); (v) comprimento médio dos textos por polaridade; e (vi) nuvem de palavras das revisões mais frequentes por classe. As análises apresentadas nesta seção são parciais e o relatório final contemplará uma exploração mais ampla do corpus.

A Figura 1 apresenta a distribuição das pontuações no corpus. Observa-se concentração nas notas extremas, com predominância de avaliações positivas sobre as negativas. Após o descarte das avaliações com nota 3, o corpus binário resultante apresenta desbalanceamento moderado entre as classes, que será tratado por meio da aplicação de pesos por classe durante o treinamento, estratégia suportada pelos classificadores investigados, de modo a reduzir o viés do modelo em favor da classe majoritária.

Os exemplos da Tabela II ilustram os principais desafios do corpus. No primeiro caso, o texto trata de um problema logístico, devolução de produto avariado, e não de uma opinião sobre o item em si, evidenciando que a polaridade da avaliação pode refletir a experiência de compra e não a qualidade do produto. No segundo, a frustração com a não entrega é

¹Disponível em <https://huggingface.co/datasets/ruanchaves/b2w-reviews01> e <https://github.com/americanas-tech/b2w-reviews01>.




Figura 1. Distribuição das pontuações (*overall rating*) no corpus B2W-Reviews01. A assimetria entre as notas extremas, com concentração em 1 e 5 estrelas, indica polarização das opiniões dos avaliadores.

reforçada por marcadores de linguagem informal e afetiva (uso excessivo de pontuação e interjeições), fenômeno comum em texto gerado por usuário que desafia modelos baseados em frequência de termos como o TF-IDF. O terceiro caso é o mais crítico para a classificação de sentimentos: o texto é explicitamente negativo, dirigido ao processo de avaliação da plataforma, enquanto a nota e a recomendação são positivas, evidenciando que a polaridade textual nem sempre reflete o sentimento do consumidor sobre o produto (4).

A Figura 2 sugere um aspecto relevante para o pré-processamento: termos como “entrega”, “prazo” e “americanas” figuram entre os mais frequentes, indicando que parte das avaliações pode tratar da experiência de compra e não do produto em si, o que tende a introduzir ruído para a tarefa de classificação de sentimento. A Figura 3 mostra que o corpus concentra produtos em categorias de eletrônicos, com Celulares e Smartphones representando cerca de 26% dos produtos únicos. As Figuras 4 e 5, analisadas em conjunto, indicam que as categorias de maior volume, como Celulares e Smartphones e Eletroportáteis, estão entre as de menor média de rating, ao passo que categorias de nicho como Linha Industrial e Agro, Indústria e Comércio concentram as avaliações mais negativas, apontando para uma distribuição de polaridade heterogênea entre domínios do corpus.

B. Visão Geral dos Pipelines

O projeto é composto por dois pipelines principais, apresentados nas Figuras 6 e 7. O primeiro abrange desde a ingestão dos dados brutos até a seleção do modelo campeão de classificação de sentimento. O segundo consome as saídas do modelo campeão para construir e avaliar o motor de recomendação orientado por sentimento.

C. Pipeline 1 – Classificação de Sentimento

1) *Divisão dos Dados*: Os dados serão divididos em três partições estratificadas por classe de sentimento:

- **Treino**: 70% dos dados.
- **Validação**: 15% dos dados (ajuste de hiperparâmetros).




Figura 2. Frequência absoluta das 20 palavras mais recorrentes no corpus B2W-Reviews01 após remoção de *stopwords*. A predominância de termos como “produto”, “entrega” e “prazo” evidencia que as avaliações cobrem tanto a qualidade do item quanto a experiência de compra.




Figura 3. Top 10 categorias de primeiro nível com maior número de produtos únicos no corpus. Celulares e Smartphones concentra quase o dobro de produtos da segunda categoria, indicando forte viés do corpus para eletrônicos de consumo.




Figura 4. Média de avaliação por categoria de produto. Categorias de entretenimento e mídia física (DVDs, Blu-ray, Livros) concentram as maiores médias, enquanto Celulares e Smartphones e Eletroportáteis, categorias com maior volume de avaliações, apresentam as menores médias, sugerindo maior incidência de experiências negativas nesses segmentos.

Tabela II
EXEMPLOS DE AVALIAÇÕES DO CORPUS B2W-REVIEWS01

Produto	Título	Texto	Nota	Recomenda?
Penteadeira JB 7200 com Banqueta Amarelo	O produto foi devolvido, devido estar avariado.	Gostaria de cancelar esta compra, peço sua gentileza me informar como devo proceder.	2	Não
Chaleira Elétrica Cadence CEL800 1,7 Litros Inox Prime	Eu não recebi o produto????!!!!!!	Eu não recebi o produto e a americanas sabe disso pois já relatei a reclamação diversas vezes!!! Só vão devolver o dinheiro no procon e isso mesmo????	1	Não
Smartphone Multitela MS80 4G 32GB	bom	que merda pq n pode so da estrela tem que escrever alguma coisa para avaliar koe americanas muda isso	5	Sim




Figura 5. Top 10 categorias com menor média de avaliação no corpus. Linha Industrial, Agro, Indústria e Comércio e Sinalização e Segurança concentram as piores médias, todas abaixo de 3,0, sugerindo que categorias de nicho e baixo volume podem apresentar maior proporção de avaliações negativas.

- **Teste:** 15% dos dados (avaliação final, utilizado apenas uma vez).

A estratificação garante que a proporção de classes positivas e negativas seja preservada em cada partição.

2) *Pré-processamento Textual:* A entrada dos modelos será o campo `review_text` concatenado ao campo `review_title`. O pré-processamento segue as etapas descritas a seguir, calibradas conforme o tipo de representação utilizada.

a) *Normalização textual (aplicada a ambas as representações):*

- 1) Conversão para minúsculas (*lowercasing*).
- 2) Remoção de HTML tags, URLs e caracteres especiais não-alfanuméricos.
- 3) Normalização de acentuação e caracteres Unicode (NFD/NFC).
- 4) Remoção de espaços duplicados e linhas vazias.

b) *Pré-processamento adicional para TF-IDF (representação esparsa):*

- 1) Tokenização por espaço e pontuação.
- 2) Remoção de *stopwords* em português (lista NLTK).
- 3) Lematização com `spaCy`.
- 4) Construção do vocabulário e aplicação do TF-IDF com *n*-gramas de 1 a 2 (*unigrams* e *bigrams*). A inclusão de bigramas permite capturar associações locais entre

termos adjacentes relevantes para o domínio, como “não recebi”, “boa qualidade” e “prazo entrega”, que perdem seu sentido quando analisadas como tokens isolados.

c) *Pré-processamento para Embeddings (representação densa):* O BERTimbau utiliza seu próprio tokenizador *Word-Piece*, que lida internamente com vocabulário, subpalavras e tokens especiais ([CLS], [SEP]). Para este modelo, aplica-se apenas a normalização textual básica, preservando a estrutura morfológica necessária para o modelo contextual.

3) *Representação da Informação:*

a) *Estratégia 1 – TF-IDF (linha de base esparsa):*

Será construída uma matriz TF-IDF com os termos mais frequentes, aplicando suavização logarítmica no cálculo do IDF para lidar com termos raros. A ponderação TF-IDF é definida pela equação:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log\left(\frac{N}{n_t}\right) \quad (1)$$

onde N é o total de documentos e n_t é o número de documentos que contêm o termo t .

b) *Estratégia 2 – Embeddings com BERTimbau:* Utilizaremos o BERTimbau Base (8) via Hugging Face. Serão investigadas duas configurações: (a) *feature extraction*, em que os pesos do BERT são congelados e o vetor do token [CLS] é usado como representação de entrada para um classificador externo; e (b) *fine-tuning* completo, em que uma camada linear é adicionada ao [CLS] e toda a rede é ajustada na tarefa de classificação binária.

4) *Modelos de Classificação:* Para cada representação, serão treinados os seguintes modelos:

- **TF-IDF + RL:** linha de base com representação esparsa e classificador linear.
- **BERTimbau + RL:** embedding contextual [CLS] com pesos congelados e classificador linear.
- **BERTimbau fine-tuning + MLP:** encoder ajustado à tarefa com classificador não-linear treinado ponta-a-ponta.

5) *Validação e Seleção do Modelo:* Todos os modelos serão avaliados com validação cruzada estratificada sobre o conjunto de treino e validação, garantindo comparabilidade entre as configurações. Para os modelos baseados em TF-IDF, serão utilizados $k = 5$ *folds* com otimização de hiperparâmetros via *Grid Search*. Para os modelos BERTimbau, dado o maior custo computacional, serão utilizados $k = 3$ *folds*. Em ambos




Figura 6. Pipeline de classificação de sentimento sobre o corpus B2W-Reviews01, desde a ingestão dos dados brutos até a seleção do modelo campeão.



Figura 7. Pipeline de recomendação orientada por sentimento, consumindo as saídas do modelo campeão para construir e avaliar o motor de recuperação e re-ranqueamento.

os casos, o modelo com melhor F1-macro médio entre os *folds* será selecionado para avaliação final no conjunto de teste.

6) *Métricas de Avaliação – Classificação*: As métricas utilizadas para avaliar os modelos de classificação de sentimento são:

- **Precisão (P)**: proporção de predições positivas corretas.
- **Revocação (R)**: proporção de positivos verdadeiros recuperados.
- **F1-score macro**: média harmônica de P e R, calculada por classe e depois com média macro (sem ponderação por frequência de classe), definida como:

$$F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad (2)$$

- **AUC-ROC**: área sob a curva ROC, medida de discriminação do modelo independente do limiar de decisão.

- **Matriz de confusão:** análise qualitativa dos tipos de erro (falsos positivos e falsos negativos).

7) *Avaliação Qualitativa:* Uma amostra aleatória estratificada de 90 instâncias do conjunto de teste será avaliada manualmente por pelo menos dois integrantes do grupo, de forma independente, quanto à polaridade real do texto. Os rótulos humanos serão comparados aos rótulos automáticos do modelo campeão. Será calculado o coeficiente de concordância Kappa de Cohen entre os avaliadores humanos.

D. Pipeline 2 – Recomendação Orientada por Sentimento

1) *Score de Sentimento por Produto:* O modelo campeão da etapa de classificação será aplicado a todas as avaliações do corpus para classificá-las como positivas ou negativas. Para cada produto único (identificado pelo `product_id`), será calculado um *score* de relevância $S(p)$ definido como:

$$S(p) = \frac{|\{\text{avaliações positivas de } p\}|}{|\{\text{todas as avaliações de } p\}|} \quad (3)$$

Apenas produtos com ao menos $n_{\min} = 5$ avaliações serão incluídos no índice de recomendação, de modo a garantir confiabilidade estatística do score.

2) *Vetorização dos Títulos de Produtos:* Os títulos de produto (`product_name`) serão vetorizados utilizando o Serafim PT* (12), uma família de sentence encoders abertos para o português com desempenho competitivo em tarefas de similaridade semântica e recuperação de informação. Será utilizada a variante `serafim-335m-portuguese-pt-sentence-encoder`, que produz vetores densos de 1024 dimensões via *mean pooling*, adequados para indexação e busca por similaridade de cosseno no banco vetorial.

3) *Banco Vetorial e Recuperação:* Os vetores de título serão indexados em um banco vetorial *open-source*, com candidatos como FAISS, ChromaDB e Qdrant, cuja escolha será definida na etapa de implementação. A busca por similaridade será realizada por *Approximate Nearest Neighbors* (ANN) com cosseno como métrica de distância:

$$\text{sim}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{|\vec{u}| |\vec{v}|} \quad (4)$$

Dado um produto de consulta q , o sistema recupera os K títulos mais similares do índice, cujo valor será definido empiricamente durante a validação do módulo de recomendação.

4) *Re-ranqueamento por Sentimento:* Os K candidatos recuperados são re-ranqueados pela seguinte pontuação combinada:

$$\text{Score}_{\text{final}}(p) = \alpha \cdot \text{sim}(q, p) + (1 - \alpha) \cdot S(p) \quad (5)$$

onde $\alpha \in [0, 1]$ é um hiperparâmetro que controla o trade-off entre similaridade semântica e positividade percebida do produto. Os produtos são ordenados de forma decrescente por $\text{Score}_{\text{final}}$ e os k primeiros são retornados como recomendações.

5) *Métricas de Avaliação – Recomendação:* Para avaliar o módulo de recomendação, serão utilizadas as seguintes métricas baseadas em ranking:

- **Precision@k:** proporção de itens relevantes nos k primeiros retornados.
- **Recall@k:** proporção de itens relevantes recuperados entre todos os relevantes.
- **NDCG@k** (*Normalized Discounted Cumulative Gain*): penaliza a posição dos itens relevantes na lista, favorecendo listas em que os melhores itens aparecem primeiro:

$$\text{NDCG@k} = \frac{\text{DCG@k}}{\text{IDCG@k}}, \quad \text{DCG@k} = \sum_{i=1}^k \frac{2^{r_i} - 1}{\log_2(i + 1)} \quad (6)$$

onde r_i é a relevância do item na posição i .

Para a avaliação do re-ranqueamento, produtos com $S(p) > 0.7$ serão considerados “altamente relevantes” e produtos com $S(p) < 0.3$ como “pouco relevantes”, criando um conjunto de referência para o cálculo das métricas acima.

6) *Avaliação Qualitativa – Recomendação:* Cada integrante do grupo avaliará de forma independente uma amostra de 20 pares consulta-lista-recomendada, julgando se as recomendações são: (a) semanticamente relevantes para o produto de consulta; (b) de alta qualidade percebida (score de sentimento elevado); e (c) diversas o suficiente para agregar valor. A concordância entre avaliadores será novamente medida pelo Kappa de Cohen.

IV. CONSIDERAÇÕES FINAIS

Este relatório parcial apresenta a proposta do projeto para a disciplina de Processamento de Linguagem Natural. O projeto aborda o problema de recomendação de produtos em e-commerce em português brasileiro, propondo a integração de análise de sentimentos com recuperação semântica por similaridade vetorial de títulos de produtos.

A abordagem em duas etapas, classificação de sentimento seguida de recomendação re-ranqueada, parte de uma análise exploratória do corpus B2W-Reviews01 que já aponta desafios relevantes: ruído linguístico, desalinhamento entre texto e nota, e heterogeneidade de domínio entre categorias de produto. O uso do TF-IDF como linha de base, combinado com o BERTimbau em duas configurações distintas, permitirá avaliar a contribuição da representação contextual frente a abordagens esparsas em um domínio de texto coloquial e ruidoso. O módulo de recomendação, apoiado no Serafim PT* para vetorização de títulos e em um banco vetorial a ser definido, integra o sinal de sentimento ao processo de recuperação por meio de re-ranqueamento ponderado.

a) *Próximos passos (a serem desenvolvidos até o Seminário 2):*

- 1) Conclusão da análise exploratória e consolidação das estatísticas do corpus.
- 2) Implementação e treinamento dos três modelos de classificação definidos.
- 3) Validação cruzada, otimização de hiperparâmetros e seleção do modelo campeão.

- 4) Implementação do Pipeline 2: vetorização de títulos, indexação no banco vetorial e re-ranqueamento.
 - 5) Avaliação quantitativa do módulo de recomendação com as métricas de ranking definidas.
 - 6) Avaliação qualitativa independente por integrantes do grupo e cálculo do Kappa de Cohen.
- [12] L. Gomes, A. Branco, J. Silva, J. Rodrigues, and R. Santos, "Open sentence embeddings for Portuguese with the Serafim PT* encoders family," in *Progress in Artificial Intelligence – 23rd EPIA Conference on Artificial Intelligence*. Springer, 2024, pp. 267–279.

REFERÊNCIAS

- [1] F. Ahmed *et al.*, "Sentiment-aware recommendation systems in e-commerce: A review from a natural language processing perspective," *arXiv preprint arXiv:2505.03828*, 2025.
- [2] M. E. Alzahrani, T. H. H. Aldhyani, S. N. Alsubari, M. M. Althobaiti, and A. Fahad, "Developing an intelligent system with deep learning algorithms for sentiment analysis of E-Commerce product reviews," *Computational Intelligence and Neuroscience*, vol. 2022, p. 3840071, 2022.
- [3] H. M. Caseli and M. G. V. Nunes, Eds., *Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português*, 4th ed. BPLN, 2026. [Online]. Available: <https://brasileiraspln.ufscar.br/livro-pln-4ed>
- [4] L. Real, M. Oshiro, and A. Mafra, "B2W-Reviews01: An open product reviews corpus," in *Symposium in Information and Human Language Technology (STIL)*, 2019.
- [5] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*, 3rd ed., 2026, online manuscript released January 6, 2026. [Online]. Available: <https://web.stanford.edu/~jurafsky/slp3/>
- [6] F. Souza and J. Souza Filho, "BERT for sentiment analysis: Pre-trained and fine-tuned alternatives," *arXiv preprint arXiv:2201.03382*, 2022.
- [7] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, Minnesota: Association for Computational Linguistics, 2019, pp. 4171–4186.
- [8] F. Souza, R. Nogueira, and R. Lotufo, "BERTimbau: Pretrained BERT models for Brazilian Portuguese," in *Proceedings of the 9th Brazilian Conference on Intelligent Systems (BRACIS)*. Cham: Springer, 2020, pp. 403–417.
- [9] C. D. Manning, P. Raghavan, and H. Schütze, "Introduction to information retrieval," 2008.
- [10] N. Vaishnavi and B. Kalpana, "Sentiment based product recommendation system using machine learning techniques," *Journal of Engineering Science and Technology Review*, vol. 16, no. 6, pp. 170–176, 2023.
- [11] N. Sharma *et al.*, "Enhancing recommendation systems with collaborative filtering and sentiment analysis: dimensionality reduction for improved content-based approaches," *Knowledge and Information Systems*, 2025.